

Lexique des Tokens & Paramètres des LLM

Guide de référence rapide pour maîtriser les curseurs et le fonctionnement interne des modèles de langage.

SECTION 01

◆ Qu'est-ce qu'un Token ?

Définition L'unité de base de découpage du texte par le LLM. Ce n'est ni un mot entier ni une lettre, mais un **fragment de texte converti en vecteur mathématique**. Le modèle ne lit pas des mots : il lit des tokens.

Règle du pouce 1 token $\approx$ 4 caractères ou 0,75 mot en anglais — un peu moins compact en français (mots plus longs, accents, espace insécable...).

Impact pratique La gestion de la **fenêtre de contexte** — la mémoire à court terme du modèle, mesurée en tokens. Au-delà de cette limite, les informations précédentes sont ignorées.

SECTION 02

⚙️ Les Paramètres Clés — Le Tableau de Bord

PARAMÈTRE	RÔLE	VALEUR BASSE	VALEUR HAUTE
🔥 Température 0.0 → 1.0+  0.0 Froid 0.5 1.0+ Chaud	Contrôle l' aléa et la créativité dans la sélection des tokens. Plus la valeur est élevée, plus le modèle explore des tokens moins probables.	0.0 – 0.2 Réponses factuelles, rigoureuses, déterministes. Code Mathématiques Extraction de données	0.7 – 1.0+ Réponses créatives, variées, inattendues. Brainstorming Écriture créative Storytelling
🗲️ Top-p Nucleus Sampling	Filtres de probabilité qui restreignent la liste des tokens autorisés parmi les plus probables. Top-p Cumule les probabilités jusqu'à un seuil p (ex : 0.9). Seuls les tokens dont la somme $\leq p$ sont retenus. Évite les tokens aberrants. Top-k Limite le choix aux k tokens les plus probables (ex : k=50). Élargit ou resserre le vocabulaire actif du modèle.		
🗲️ Top-k Fenêtre de sélection			

SECTION 03

⚠️ Les Limites Fondamentales à Garder en Tête



L'illusion de la conscience

Un LLM ne "**pense**" pas. Il **prédit statistiquement le token suivant** d'après les milliards de séquences apprises lors de son entraînement. Il n'y a aucune compréhension, aucune intention, aucune conscience derrière la réponse.



L'hallucination

Puisqu'il cherche le **mot le plus probable** et non le "vrai", le modèle peut **affirmer des faussetés avec une assurance parfaite**. Une réponse confiante n'est pas une garantie de vérité : vérifiez toujours les faits critiques.

➡ À RETENIR — LES 3 RÉFLEXES ESSENTIELS

① Pensez en tokens, pas en mots

Surveillez votre consommation de contexte. Un prompt long = moins de mémoire disponible pour la réponse.

② Ajustez la température selon le besoin

Tâche précise → basse (0.1–0.3). Tâche créative → haute (0.7–1.0). Ne laissez pas la valeur par défaut décider pour vous.

③ Vérifiez toujours les faits critiques

Un LLM confiant n'est pas un LLM exact. Pour tout fait sensible, croisez avec une source primaire fiable.